L5-6 讲义：智能体 (Agent) 设计与实现

课程: MBA 大模型智能体课程
课时: 第 5-6 讲 (共 3 小时)
适用: 讲师备课 / 学生预习与复习

本讲关键问题

作为 MBA 学生，学完这一讲你应该能回答：

1. **Agent 和普通 AI 助手有什么本质区别？** → 自主决策 vs 被动响应
2. **什么场景该用 Agent，什么场景用 Workflow 就够了？** → 决策框架
3. **Agent 为什么有时候会"跑飞"？如何控制？** → 护栏设计
4. **市面上这么多 Agent 产品，怎么评估和选择？** → 评估体系
5. **我想在业务中引入 Agent，从哪里开始？** → 落地路径

为什么这节课是核心

前两节课（L1-4）我们学了 LLM 和 Workflow。你可能会想："我已经会用 ChatGPT 了，会用 LangChain 搭流程了，还要学什么？"

Agent 是质的飞跃：

能力	ChatGPT/Claude 对话	Workflow 编排	Agent 系统
主动性	被动回答	按流程执行	**自主决策下一步**
工具使用	有限内置	预设调用	**动态选择工具**
错误处理	用户重新问	中断报错	**自我修复重试**
复杂任务	单轮完成	线性流程	**多步骤、分支决策**

商业价值：Agent 能处理传统软件无法自动化的"灰色地带"——那些需要判断、需要灵活应对的任务。

目录

1. 什么是 Agent?
2. Agent 核心架构
3. 五大设计模式
4. ReAct 与推理行动循环
5. 反思与自我改进
6. 工具调用 (Tool Calling)
7. 前沿 Agent 框架与产品 □ 新增
8. Agent 评估体系
9. 实践案例
10. 参考资料

---

1. 什么是 Agent?

1.1 一个商业场景理解 Agent

场景：你是一家电商公司的客服总监，每天有 1000 个客户问题需要处理。

传统方式：- FAQ 机器人：能回答"退货政策是什么"，但问"我的订单为什么还没到"就懵了 - 人工客服：能处理复杂问题，但成本高、不能 7×24

Agent 方式：- 客户问："我的订单为什么还没到？"- Agent **自主决定**：先查订单系统 → 发现物流异常 → 查快递公司 API → 发现包裹丢失 → 自动发起补发流程 → 给客户发通知 - 整个过程不需要人工介入，Agent 自己判断该做什么

这就是 Agent 的本质：能自己想、自己做、自己判断下一步的 AI 系统。

1.2 技术定义

Agent（智能体）= 用 LLM 来决定下一步行动的系统

与传统软件的根本区别：

传统软件	Agent
程序员写死所有逻辑	LLM 实时决定做什么
遇到意外情况就报错	遇到意外自己想办法
每种情况都要预先编程	可以处理从未见过的情况

1.3 官方定义对比

来源	定义	MBA 解读
OpenAI	"Agents are systems that independently accomplish tasks on your behalf."	可以替你独立完成任务
Anthropic	"Systems where LLMs dynamically direct their own processes and tool usage"	自己决定用什么工具、怎么用
Lilian Weng	"Agent = LLM + Memory + Planning + Tool Use"	大脑 + 记忆 + 规划 + 执行能力

1.4 Agent vs Workflow —什么时候用哪个？

这是 MBA 最常问的问题：我什么时候该用 Agent，什么时候 Workflow 就够了？

场景特征	用 Workflow	用 Agent
流程确定性	步骤固定、不会变	需要根据情况灵活调整
决策复杂度	简单 if-else 能搞定	需要"判断"和"权衡"
异常处理	异常情况可枚举	什么异常都可能发生
可解释要求	必须 100% 可预测	可以接受一定不确定性
开发成本	前期投入换后期稳定	快速上线、迭代优化

真实案例：

任务	推荐方案	原因
发票自动录入	Workflow	格式固定，规则明确
客户投诉处理	Agent	每个投诉都不一样，需要判断
日报自动生成	Workflow	模板固定，数据拼接
竞品分析报告	Agent	需要搜索、判断、综合
订单状态查询	Workflow	纯数据查询

任务	推荐方案	原因
退款审批	Agent	需要判断是否合理

---

2. Agent 核心架构—产品经理必须理解的四要素

2.1 为什么要理解架构?

作为产品经理或业务负责人，你不需要会写代码，但需要理解 Agent 的"零件"，才能：- 评估供应商方案是否靠谱 - 判断某个需求技术上是否可行 - 理解为什么 Agent 有时候会出错 - 知道怎么和技术团队沟通

2.2 Agent 四要素公式

- ☐ 来源: Lilian Weng - LLM Powered Autonomous Agents

```
Agent = LLM + Memory + Planning + Tools
        大脑    记忆      规划       执行
```

商业类比：把 Agent 想象成一个远程员工

组件	类比	缺了会怎样?
LLM（大脑）	员工的思考能力	不能理解任务、不会判断
Memory（记忆）	员工的笔记本	每次都从头开始，不记得之前做过什么
Planning（规划）	员工的项目管理能力	只能做简单任务，复杂任务会乱
Tools（工具）	员工能用的软件/API	只能说不能做，纸上谈兵

2.3 四要素详解

(1) LLM —选什么模型?

考量	选择
任务复杂度高	GPT-4, Claude Opus, Gemini Pro
成本敏感	GPT-4-mini, Claude Haiku, Qwen
需要最新信息	带搜索工具的任何模型
数据隐私	本地部署的开源模型

最佳实践（OpenAI 建议）：先用最强模型验证可行性，再降级到便宜模型优化成本。

(2) Memory —记忆系统

类型	存在哪里	作用	容量
工作记忆	Context Window	当前对话	128K-1M tokens
短期记忆	会话缓存	这次会话的历史	按需
长期记忆	向量数据库	用户偏好、历史知识	无限

商业价值：有记忆的 Agent 能实现"个性化服务"——它记得你的偏好、历史、习惯。

(3) Planning —规划能力 Agent 如何把复杂任务拆解成可执行的步骤。

例子：用户说"帮我分析竞争对手"

差的Agent：直接开始写分析报告（可能跑偏）

```
好的Agent：
1. 先问清楚：分析哪个竞争对手？关注哪些维度？
2. 拆解任务：收集信息 → 财务分析 → 产品对比 → 市场定位 → 总结
3. 逐步执行，每步检查是否在正轨
4. 最后汇总成报告
```

(4) Tools —执行能力

工具类型	例子	用途
数据工具	数据库查询、API 调用	获取信息
动作工具	发邮件、创建工单、执行代码	产生影响
感知工具	网页浏览、图像识别	理解环境

关键认知：没有工具的 Agent 只是聊天机器人，有工具的 Agent 才能"做事"。

2.4 Agent 执行闭环（最小系统）

```
用户目标 → LLM判断 → 调用工具 → 获取结果 → 更新状态
              ↑                              ↓
                    未完成则继续循环
```

MBA 要点：这个循环可能执行 1 次（简单任务），也可能执行 100 次（复杂任务）。每次循环都有成本（API 调用费），所以设计 Agent 时要考虑"平均循环次数"。

---

3. 五大设计模式—从简单到复杂

- ☐ 来源: Anthropic - Building Effective Agents

为什么要学设计模式?

就像建筑有不同的结构（平房、高楼、桥梁），Agent 也有不同的架构模式。选对模式，事半功倍；选错模式，事倍功半。

3.1 模式选择决策树

```
你的任务需要多少"智能"？

简单增强        模式1: Augmented LLM
                  (LLM + 检索/工具)

多步骤串行       模式2: Prompt Chaining
                  (流水线)

需要分流        模式3: Routing
                  (分类分发)

可以并行        模式4: Parallelization
                  (同时执行)
```

```
复杂协作        模式5: Orchestrator-Workers
                  (主Agent协调多个子Agent)
```

3.2 模式详解

---

4. ReAct 与推理行动循环

4.1 ReAct 框架

- ☐ 来源: ReAct: Synergizing Reasoning and Acting

ReAct = **Re**asoning + **Act**ing

```
Thought: 我需要查找2024年AI领域最重要的突破...
Action: search("2024 AI breakthroughs")
Observation: 搜索结果显示...

Thought: 现在我有足够信息来回答用户问题了。
Action: finish("2024年AI领域三大突破是...")
```

4.2 为什么 ReAct 有效?

优势	说明
可解释性	每一步都有明确的推理过程
可调试性	可以检查中间状态定位问题
灵活性	可根据观察结果动态调整策略
准确性	通过工具获取真实信息，减少幻觉

---

5. 反思与自我改进

5.1 Reflexion 框架

- ☐ 来源: Reflexion: Language Agents with Verbal Reinforcement Learning

Reflexion 让 Agent 从失败中学习:

执行任务 → 失败 → 反思原因 → 存入记忆 → 重试（带着经验）

5.2 反思的三个层次

层次	内容	示例
即时反思	当前步骤的问题	“这个 API 调用参数错了”
轨迹反思	整个执行路径的问题	“我应该先查数据库再调用 API”
策略反思	通用策略的改进	“遇到权限错误时应该先检查 token”

---

6. 工具调用 (Tool Calling)

6.1 工具调用基础

工具让 Agent 能够: - 获取实时信息（搜索、API）- 执行计算（代码、数学）- 与外部系统交互（数据库、服务）

6.2 工具设计四原则

原则	说明	反例
原子性	一个工具做一件事	☐ `search_and_summarize()`
明确性	清晰的输入输出定义	☐ 模糊的参数描述
幂等性	多次调用结果一致	☐ 依赖隐藏状态
安全性	明确权限边界	☐ 无限制的文件访问

---

7. 前沿 Agent 框架与产品 ☐ 新增

截至 2026 年 2 月，Agent 领域的主要玩家

7.1 编码 Agent

Devin (Cognition Labs)

- **定位**: 世界首个全自主 AI 软件工程师 (2024 年 3 月首发)
- **能力**: 规划、代码生成、调试、部署的全流程自主完成
- **最新**: Devin 2.2 (2026 年 2 月) - 3x 更快启动、Devin Wiki 文档生成
- **定价**: 按需付费计划，$500/月专业版
- **官网**: devin.ai

Claude Code (Anthropic)

- **定位**: 终端内的 Agentic 编码助手
- **能力**:
  - 读取、修改、执行代码
  - 支持 CLAUDE.md 项目配置文件
  - Thinking Mode 深度推理 (Opus 4.5)
- **最新**: v2.1.50+ (2026 年 2 月)
- **特色**: 与 MCP 深度集成，支持长时间运行 Agent
- **安装**: `npm install -g @anthropic-ai/claude-code`
- **官网**: github.com/anthropics/claude-code

Codex (OpenAI)

- **定位**: OpenAI 官方编码 Agent，Web+CLI 双端
- **能力**:
  - Codex Web: 云端沙盒环境，GitHub 集成
  - Codex CLI: 本地终端执行，读写运行代码
- **最新**: 2025 年 4 月发布，持续迭代中
- **模型**: codex-1, gpt-5.3-codex
- **官网**: openai.com/codex

7.2 AI IDE

Cursor

- **定位**: 基于 VS Code 的 AI-First IDE
- **核心能力**:
  - **Composer Mode**: 高级任务规划和多文件生成
  - **Background Agents**: 后台异步执行任务
  - **Browser Control**: 内置浏览器自动化

  - **Plan Mode**: 执行前先规划
- **最新**: v2.5 (2026 年 2 月) - Plugins、Sandbox、Async Subagents
- **定价**: $20/月 Pro，$40/月 Business
- **官网**: cursor.com

Windsurf (Codeium)

- **定位**: AI 原生 IDE，前身为 Codeium
- **核心能力**:
  - **Cascade**: Agentic AI，理解代码库、多文件编辑、终端执行
  - **Persistent Memory**: 跨会话记忆
  - 自动运行 pytest/pylint/radon 诊断
- **特色**: 对低代码/快速原型友好
- **官网**: windsurf.com

7.3 通用 Agent 框架

OpenClaw ☐ GitHub 239K+ Stars

- **定位**: 开源 AI 超级 Agent 框架 (2025 年 11 月发布)
- **核心能力**:
  - 多渠道消息集成 (Discord, Telegram, Slack, WhatsApp 等)
  - MCP 协议原生支持
  - Skills 系统（可扩展能力）
  - 多 Agent 协作 (spawn subagents)
- **最新动态**: 创始人加入 OpenAI，项目转为开源基金会维护
- **特色**: 个人 AI 助手的最佳选择
- **一行安装**:

```
# macOS / Linux
curl -fsSL https://openclaw.ai/install | sh

# Windows (PowerShell)
irm https://openclaw.ai/install.ps1 | iex

# NPM (跨平台)
npm install -g openclaw
```

- **官网**: openclaw.ai | docs.openclaw.ai

Manus (已被 Meta 收购)

- **定位**: 全自主数字 Agent (2025 年 3 月发布)
- **核心能力**:
  - 基于 Transformer LLM + Agent 框架
  - 独立完成复杂任务：旅行规划、市场研究、竞品分析
  - Context Engineering 深度优化（架构重构 4 次）
- **最新**: 2026 年被 Meta 收购
- **论文**: arxiv.org/html/2505.02024
- **官网**: manus.im

7.4 企业级 Agent

Claude Cowork (Anthropic)

- **定位**: 面向企业知识工作的 Agent 平台 (2026 年 1 月预览版)
- **核心能力**:
  - Microsoft Office 插件 (Excel→PowerPoint 跨应用协作)
  - 企业级 Plugins (财务/法务/HR)
  - Google Workspace / Asana 集成
- **特色**: Claude Code 证明了编码领域的成功，Cowork 将同样模式扩展到所有知识工作
- **适用**: 企业办公自动化
- **官网**: anthropic.com/cowork

7.5 框架对比总结

框架/产品	定位	开源	适用场景	核心优势
Claude Code	CLI 编码 Agent	☐	开发者日常编码	Thinking 模式、MCP 集成
Codex	云 + 本地编码 Agent	☐	企业级开发	GitHub 深度集成
Cursor	AI IDE	☐	项目级开发	Composer、Background Agents
Windsurf	AI IDE	☐	快速原型	Cascade、持久记忆
Devin	全自主工程师	☐	端到端交付	完全自主执行
OpenClaw	通用 Agent 框架	☐	个人 AI 助手	多渠道、Skills 生态
Manus	数字 Agent	☐	复杂任务自动化	Context Engineering
Claude Cowork	企业知识 Agent	☐	办公自动化	Office/Workspace 集成

7.6 选型建议

场景	推荐
个人开发者日常编码	Claude Code / Cursor
企业级代码交付	Codex / Devin
快速原型/学习	Windsurf
构建个人 AI 助手	OpenClaw
企业办公自动化	Claude Cowork
复杂任务自动化	Manus (via Meta)

---

8. Agent 评估体系

☐ 来源: Anthropic - Demystifying Evals for AI Agents

8.1 核心概念

术语	定义
Task	单个测试用例，有明确输入和成功标准
Trial	对同一 Task 的一次执行尝试
Grader	评分逻辑，检查某个方面的表现
Transcript	完整执行记录

8.2 三类评分器 (Grader)

类型	方法	优势	劣势
Code-based	字符串匹配、单元测试	快速、确定性	对有效变体不灵活
Model-based	LLM 评分、Rubric 评估	灵活、能处理开放任务	非确定性
Human	专家评审	金标准质量	贵、慢

8.3 关键指标：pass@k vs pass^k

指标	含义	适用场景
pass@k	k 次尝试中至少 1 次成功	只要有一个方案 work
pass^k	k 次尝试全部成功	面向用户，要求一致性

---

9. 实践案例

9.1 市场研究 Agent

目标：48 小时内产出《某细分行业进入建议》

架构：

```
User Query
    ↓
Planner（拆任务）
    ↓
Research Agent（搜索/抽取）
    ↓
Analysis Agent（计算/对比）
    ↓
Writer Agent（生成报告）
    ↓
Reviewer（质量检查）
```

9.2 使用 OpenClaw 构建个人助手

示例配置：

```
# SOUL.md - 定义 Agent 人格
你是我的个人 AI 助手，负责：
- 管理日程和提醒
- 研究和信息收集
- 文档整理和写作辅助

# Skills 配置
skills:
  - apple-reminders   # 提醒管理
  - himalaya          # 邮件处理
  - web-search        # 网络搜索
```

---

10. 参考资料

必读

- OpenAI: A Practical Guide to Building Agents
- Anthropic: Building Effective Agents
- Lilian Weng: LLM Powered Autonomous Agents
- Manus: Context Engineering for AI Agents ☐ 新增

论文

- ReAct - Yao et al., 2023
- Reflexion - Shinn & Labash, 2023
- Manus AI Architecture - 2025 ☐ 新增

框架与工具

- OpenClaw - 开源 Agent 框架
- Claude Code - Anthropic CLI Agent
- Codex - OpenAI 编码 Agent
- Cursor - AI IDE
- Windsurf - AI IDE
- LangGraph

课后思考题

1. 比较 Claude Code、Codex、Devin 三个编码 Agent，哪个最适合你的工作场景？
2. 如果你要构建一个个人 AI 助手，会选择哪个框架？为什么？
3. 设计一个 Agent 来自动化你工作中的一个重复性任务。

本讲义最后更新：2026-02-28