第3-4课 | 流 RAG

MBA《 模型智 》

：从" 聊 " " 完 任 "
：90 钟 含

今　　将掌握什么?

1. 什么单　LLM调　　企　中　够
2. 　　流　　模　：顺序、并　、条件　支
3. RAG原　：检索、向量　、　　块、
4. 何把　　流 + RAG落　真
5. 何评估效　、控　　风险

课程结构 90 钟

模块	容	
A	什么需 流	15 min
B	流 模	20 min
C	RAG原 键 术	30 min
D	场景落 操	20 min
E	总结 讨	5 min

先做一 判断

> "只 Prompt写得 ，复杂 也 一 调 搞 。"

- A. 确
- B. 错误

答案：B 企 任 都需 步骤编排

单 调 的4 然短板

短板	结
有限	档/ 档处 完整
识陈旧	答 新事
状态执	难 跟踪任
缺乏	调 统完 任

短板1：　　限的

- 企　常见输　：　　包、财　　集、历史　单
- "塞　　"≠"　解　　"
- 即使　　很　，也　带　：
  - 费　　升
  - 速　　降
  - 　　稀释

> 结　：必须做任　　解　检索

短板2：模型 " "的 识

- LLM预训练 识有截止日期
- / 册/ 议纪 语料
- 纯 容易" 起 ，但并 真 "

RAG价值：把"企 私有 识" 模型

短板3：复杂任　　一句

典型任　：

- "帮　写竞　　析并给　　建议"

隐　步骤至少包括：

1.　集
2. 交叉验证
3. 结构　　析
4. 输　　格
5.　　复核

短板4：一步　　利　风控

- 　　错误　　哪一步
- 　给　　审计的中　结
- 　设置"　　审批点"

企　需：　追踪、　　溯、

什么　　流　Workflow

义：把复杂任　拆　　执　节点，并　义节点　　的依赖　　。

```
→　1(　) →　2(　) →　3(　) →
```

流强调：

- 流程确
- 中　　见
- 错误　恢复

流带　的商　价值

准确率↑　一致　↑　风险↓　维护　↑

1. 结　　稳　：标准　流程
2. 团队　协　：节点职责清晰
3.　持续优　：　替换单　节点
4.　运营：　监控每一步　　延

流　　模　总览

模	核	典型　途
顺序　Pipeline	先做什么　做什么	档处　链
并　Parallel	哪些　做	源　析
条件　支　Router	根据什么走　路径	流

模　一：顺序执　　Pipeline

```
↓
　　→　　→　　→
```

适　　：

- 　　游强依赖
- 需　逐步精炼
- 每步都有　确输　输

顺序模 的设计 点

1. 每 节点只做一件事 单一职责
2. 中 结 结构 JSON优先
3. 键节点设置质量 槛
4. 失败节点支持重试 降级

顺序模　示例：研

节点	输	输
N1　据　集		原始　料包
N2 事　整	料包	结构　事
N3　析	事	SWOT结
N4　稿	SWOT	Markdown/PPT摘

顺序模　伪代码

```
facts = extract(raw_docs)
checked_facts = verify(facts)
analysis = reason(checked_facts)
report = format_report(analysis)
return report
```

> 每一步都　单测，便　团队并　　。

试试 1：Prompt链　执

台直达链　：

- DeepSeek Chat
- Kimi 智　助

任　：　"某　　"　　简

1. 先　取事　2) 再做SWOT 3)　　500字摘
　　比"一　　让模型写完"　"链　执　"的质量差异。

模　二：并　执　　Parallel

并　价值：

- 降低总耗
- 增强覆盖
- 避免单一　角偏差

并　模　适　场景

- 　源搜索　新闻+财　+　坛
- 角色评审　　+财　+
- 假设评估　乐观/中　/悲观

：并　　"把　一件事重复3遍"。

并　模　的两　核

1. **结　冲突怎么处　?**
    - 置　　排序
    - 引　　源优先
2. **汇总器怎么写?**
    - 先归纳共　点
    - 再列　　歧　原因

并　模　伪代码

```
a = analyze_finance(data)
b = analyze_market(data)
c = analyze_product(data)
final = merge([a, b, c], strategy="evidence_first")
return final
```

试试 2： 角 并 析

台直达链 ：

- Kimi
- Gemini

任 ： "AI 2026 的 点 什么？"
别从： 术、渠 、 、监管四 角 独立 ，再做统一汇总。

模　　：条件　支　Router

```
        →
            ├─          →
            ├─          →
            └─          →
```

核　：先　　，再执　　流程。

Router的 键： 标准

- 标签 互斥且穷尽 MECE
- 置 阈值 确
- 低置 走"兜底路径"

> 确 ，宁 转 ， 乱答。

Router常见　　策略

策略	优点	风险
规则优先　　键词	稳　　控	覆盖有限
LLM	灵	一致　波
混　策略	衡稳　　灵	统　复杂

Router伪代码

```
intent, score = classify(user_query)
if score < 0.65:
    return handoff_to_human(user_query)
elif intent == "refund":
    return refund_workflow(user_query)
elif intent == "consult":
    return consult_workflow(user_query)
else:
    return complaint_workflow(user_query)
```

试试 3：做一　　流器

台直达链　：

- OpenAI Playground
- Claude

任　：把　消　　`/　/　/　`，并输　JSON：

`{"intent":...,"confidence":...,"reason":...}`

种模　　何组　？

企　真　流程　常　：

```
Router(     ) → Parallel(       ) → Pipeline(       )
```

　就　"组　编排"思想。

流质量指标　　角

指标	解释
功率	任　　终完　比例
一　　率	需　　返
均耗	从输　　输
单任	API+算　+
解释	否追踪证据链

流 vs Agent　再　比

维	流	Agent
决策路径	预　义	态规划
靠		中
灵	中	
	低	

MBA建议：先　流，　Agent增强。

什么场景先　Workflow，什么场景　Agent?

- **Workflow优先**：标准　流程、监管　求　、容错低
- **Agent优先**：探索　任　、　放目标、路径　确
- **混　　案**：Agent做规划，Workflow做执

低代码　　流　台：Coze

Coze　字节跳　　的AI Bot　　台，　供　　流编排。

点	
编排	拖拽　节点连　，　需代码
模型支持	豆包、GPT、Claude
插件　态	100+官　插件，支持　　义
一键　布	布　飞书、　　、网
免费额	免费使

口：coze.cn　　/ coze.com　海

Coze 核　概念

概念		比
Bot	一　完整的AI应	程序
Workflow	流程编排	流程
Plugin	调	API　口
Knowledge	识库　RAG	参考　料
Memory	记忆	聊　历史

Coze Workflow 节点　型

节点　型	功	使　场景
LLM	调　模型	、　析
Code	运　代码	据处　、计算
Knowledge	识检索	RAG　答
Plugin	调　插件	搜索、API调
Condition	条件　支	流程控
Loop	循环处	批量任
Variable	变量操	据存储

Coze 案例1：智　　Bot

场景：　商售　　复

Workflow设计：

```
　　→　　(LLM) →
　　　
```

Coze 案例2：日　　助

场景：每日　　讯日

Workflow设计：

```
    →      (Plugin) →
                      ├       →      (LLM)
                      ├       →      (LLM)
                      └       →      (LLM)
     →      (LLM) →      /
```

**效　**：

- 每　6:00　　送
- 覆盖50+　　源
- 节省2　　/　　整

Coze 案例3：　　试助

场景：HR筛选简历+　　试

Workflow设计：

```
      (PDF) →        (LLM) →    JD(Knowledge)
            →        (LLM) →
                              ├      →
                              └      →
```

**效　**：

- 简历筛选效率　升5倍
- 　试　　针　　强
- 减少　观偏见

Coze 案例4：　议纪　助

场景：　议　音　　纪

Workflow设计：

```
      →         (Plugin) →       (LLM)
       →
          ├       (LLM)
          ├       (LLM)
          └       (LLM)
       →         (LLM) →
```

**效　**：

- 30　钟　议 → 2　钟　纪
-　　识别待办事项
- 支持　语言

Coze 案例5：投研　析助

场景：　　快速调研

Workflow设计：

```
        →
            ├        (Plugin)
            ├        (Plugin)
            ├        (Knowledge)
            └        (Plugin)
          →        (LLM) →
          →        (LLM) →    PDF
```

**效　**：

- 5　钟完　初步调研
-　　据　源　追溯
- 支持　期跟踪

试试：Coze快速

台直达：coze.cn

10 钟任 ：

1. 册账 ，创建新Bot
2. 添 一 简单Workflow： → LLM →
3. 测试 效
4. 尝试添 一 Plugin节点 ：搜索

渡：　什么　RAG?

即使流程设计很　，　　识　源　　靠，输　仍　　靠。

RAG解决的　　：

1. 给模型"　查证"的　　识
2. 让　答基　证据而非记忆

RAG一句　　义

RAG = Retrieval + Generation

- 检索　Retrieval　：找　　料
- 　　Generation　：基　　料组织　答

> 核　　"　　写"，而　"　　找"。

RAG　纯LLM的差异

	据　源	追溯	幻觉风险
纯LLM	参　记忆	弱	
RAG	识库 + 参	强	低

RAG总架构　两阶段

```
                  →     →       →
                    →    TopK →     →
```

离　决　"搜得　　",　　决　"答得准　准"。

阶段1：离　索引　Indexing

1. 　档采集：PDF、网　、　格、　识库
2. 　　清洗：去噪、去模板、补元　据
3. 　块：控　粒　　完整
4. 向量　：　　转Embedding
5. 存储：向量库 + 元　据索引

阶段2：　　检索　Retrieval

1. Query　解　改写
2. 召　　Top-K
3. 重排　Re-rank
4. 组装
5. 约束　　含引

阶段3：Grounded Generation

的RAG 答应该：

- 确引 源
- 确 " "
- 给 验证证据 段

荐 示词约束：

```
" "
```

向量 Embedding 什么?

把 映射 维向量空 :

- 语义 近 → 距离近
- 语义 → 距离远

```
"          " ↔ "          "
"          " ↔ "          "
```

向量　直觉　　概念

```
    :     ●    ●    ●

    :      ●   ●   ●
```

检索　质：找　　向量"　近"的若干　　块。

Embedding模型怎么选?

模型	维	点	适 场景
OpenAI text-embedding-3-large	3072	语言强	场景
BGE-M3	1024	中 优 ， 源	中 场景
Jina-embeddings-v3	1024	支持	档检索
Cohere embed-v3	1024	语言、企 级	企 应
GTE-Qwen2	1024	阿里 源，中 强	中 +代码

选型 键维 ：语言覆盖、领域适配、向量维 、

似　计算：常　指标

- 余弦　似　　Cosine
- 点积　Dot Product
- 欧氏距离　L2

程中，余弦　常见；　键　　模型训练目标一致。

试试 4：　见"语义　似"

台直达链　：

- Hugging Face Spaces
- OpenAI Embeddings Guide

任　： 输　3组句　，观察　似　　，验证"语义　近并非词　　"。

向量 据库 做什么?

向量 据库 只 "存向量", 包括:

- 近似 近邻搜索 ANN
- 元 据 滤 / / 档 型
- 扩容 并 查询

据库	点	适 场景
Milvus	布 ,	规模
pgvector	PostgreSQL扩展	已有PG基础设施
Qdrant	Rust , 快速	中 规模
Chroma	轻量级	原型
Pinecone	托管SaaS	快速
Weaviate	语义搜索原	AI应

Top-K 底取 少?

- K太 ： 漏召
- K太 ：噪声 、

践建议 起步 ：

- 召 `K=20`，重排 取`Top 5~8`

重排 Re-rank 什么重 ?

流程:

1. 粗召 快
2. 精重排 准

益:

- 显著 升 终答案质量
- 降低" 似 但 "的干扰

块 Chunking 什么 键?

块 RAG效 的" 基"。

- 太 ：召 粗糙
- 太 ：语义断裂
- 重叠：边界 丢失

常见　块策略　比

策略	做	适　场景
固	每N字切	快速起步
段落切	按　然段/标	档结构清晰
语义切	根据语义变　切	精　优先
混　切	标　+　+重叠	环境常

块　　重叠率　验值

建议起点：

- 中　：`300~800 /`
- 重叠：`10%~20%`

根据任　调参：

-　答偏事　：块　　一点
- 复杂　　：块　稍

结构　　档的　块　巧

针　　/财　/　册：

1. 先按章节标　切
2. 保留层级路径　　`3.2.1`
3. 块　附带元　据　　码、　　、日期

元　据　　续引　　审计的　键。

试试 5：Chunk参　　验

台直达链　：

- Dify
- Coze

**任　：　一　**档尝试两组参　：

A: `chunk=300 overlap=30`

B: `chunk=800 overlap=120`

比较：召　　、　答完整　、延迟。

Query改写：让"搜" 聪

常常 短、 口语 。 先做：

- 键词扩展
- 义词补
- 范围补充

示例：

`" "` → `" 12 "`

混　检索：Dense + Sparse

- Dense　向量　：擅　语义　似
- Sparse　　键词/BM25　：擅　精确词匹配

混　检索　　兼顾：

-　有　词准确命中
- 语义　　扩展召

Anthropic: Contextual Retrieval

> 源: [Contextual Retrieval](#) (Anthropic, 2024)

：传统RAG 块 丢失

```
chunk: "The company's revenue grew by 3%..."
:
```

解决 案： LLM 每 chunk 缀

```
chunk: "This chunk is from ACME Corp's Q2 2023
SEC filing. The company's revenue grew by 3%..."
```

Contextual Retrieval 效

	Top-20检索失败率
传统RAG	5.7%
+ Contextual Embeddings	3.7% (↓35%)
+ Contextual BM25	2.9% (↓49%)
+ Reranking	**1.9%** (↓67%)

：借助Prompt Caching，约$1/百万token

RAG常见失败模

1. 检索 Recall 足
2. 检索错 Precision 足
3. 胡 未约束
4. 源冲突 未做证据 齐
5. 档 识库未 新

何评估RAG效 ？

维	指标示例
检索层	Recall@K, MRR, nDCG
层	Faithfulness, Answer Relevancy
层	单解决率、 管率

评估必须 层， 只 " 观 "。

试试 6：搭一　迷　RAG Bot

台直达链　：

- Dify Cloud
- Coze Studio

任　：　传10　　档，配置　识库　答Bot，测试5　　，记　：

1.　否给　处 2)　否　答超范围　　3)　否　　幻觉

Workflow + RAG 怎么结　？

典型组　：

```
Router → (RAG       ) →        →        →
```

　点：RAG　　独立　　，而　　流中的"　识供给模块"。

企　参考架构　简

层	
层	Chat/API/企　IM
编排层	Workflow/Router/监控
识层	档库/向量库/元　据
模型层	Embedding + LLM + Re-ranker
层	限、审计、评估、　警

应　场景1：智

流程：

1. Router识别
2. RAG查找　识条款
3.　　答复 +　源
4. 低置　　转

益：

- 　响速　　升
- 　　坐席压　　降
- 口径一致　　升

应　场景2：投研助

- 并　拉取：财　、新闻、研
- RAG保障事　依据
-　　流　　：日　/周　/策略　忘

管　层价值：

- 缩短　　决策的链路

应　场景3：　　审查

- 按条款　块比　标准模板
- 检索历史风险案例
-　　风险　级　修改建议

键　求：

- 必须　追溯　条款　段
- 必须保留　　终审

应　场景4：员　　识助

- 覆盖　　、流程、FAQ、SOP
- 　答附"　档　码 +　新　　"
- 　期　识　　降

场景　常ROI　快。

延怎么控?

1. 优先优　检索，减少　效
2.　模型做　　/改写，　模型做　终
3. 缓存　频
4.　级　　普　　答 vs　价值　答

限　　忽

- 按　　身份做　档访　控　　RBAC
- 敏感字段脱敏　　、身份证、　　额
-　 链路日志审计
- 避免把　密　　送　　规模型

路　Human in the Loop

建议把　　审核放　：

- 　风险结　输
- 　　/财　/医疗　　键场景
- 低置　　支

"　　"　　目标，"　控　　"才　目标。

从0 1 施路 第1 月

1. 选一 频低风险场景
2. 整 规模 质量 识库
3. 搭建 Workflow + RAG
4. 做A/B测试 评估

从1　10扩展路　　季

- 增　场景覆盖　　→　　→HR
- 建立统一　识　　规范
- 建立评估　板　　警
- 　　组织培训　流程改造

常见反模　　Anti-pattern

1. 一　　追求"　　一统　台"
2. 只　Demo，　　指标
3. 忽略　识　新
4.　做　限隔离
5. 把Agent　"万　员　"

MBA 角： 需 做的5 决策

1. 先切哪 场景?
2. KPI 何 义?
3. 谁负责 识 ?
4. 风险红 哪里?
5. 何 衡效率 规?

组讨　　8　钟

按　组　答:

1.　　适　先落　哪　场景?

2. 该场景的　键　识源　什么?

3. 哪　环节必须保留　　?

4. 预期3　月　　升什么指标?

课堂练习任　卡

任　：设计一　"企　　识　答"　　流程
输　　求：

- 至少包含`Router + RAG +`
- 给　3　　键指标
- 给　1　风险控　点

试试 7：　　流程搭建

台直达链　：

- Langflow
- Flowise
- n8n

任　：画　并运　一　"查询→检索→　答→引　"的流程，截屏保存。

试试 8：评估　的RAG

台直达链　：

- Ragas　档
- TruLens

任　：　　一　识库构造10　测试　　，记　`　　/　　/　　`。

课重点　顾　1/2

- 流让任　拆解、　监控、　优
- 模　有复杂编排的基础积木
- 企　落　先追求稳　，再追求

课重点　顾　2/2

- RAG　质　"把　　识　　模型　　"
- 向量　决　"　否找　　"
-　　块策略决　"检索质量　限"
- 评估　　决　"　否规模　　"

荐阅读　　具清单

- RAG　　：Lewis et al. 2020
- Self-RAG (Asai et al., 2023)
- RAPTOR (Sarthi et al., 2024)
- CRAG (Yan et al., 2024)
- Pinecone: Advanced RAG
- Anthropic: Contextual Retrieval　已验证
- LlamaIndex　档
- LangChain　档

课　　选

1. 选择一　　熟悉的　　场景
2. 画　Workflow流程　　至少6　节点
3. 给　RAG　识源　　块　案
4.　交1　"　　风险清单"

一课预

第5-6课 ：Agent架构 具调

- Agent的规划、记忆、 具、反思
- 智 协 失败恢复
- 企 级Agent 框架

Q & A

谢谢

带走一句：

先把流程做，再把智做强。